

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



Chủ đề:

DỰ ĐOÁN CHỈ SỐ CHẤT LƯỢNG KHÔNG KHÍ (AQI)

GV hướng dẫn : PGS.TS. Vũ Văn Thiệu

Học phần : Tính toán khoa học (IT4110)

Mã lớp : 161377

Nhóm : 15

Danh sách thành viên nhóm

STT	Họ và tên	Mã số SV
1	Trần Ngọc Mai	202416976
2	Hoàng Ngọc Thịnh	202417044
3	Nguyễn Thị Thanh Trúc	202417052
4	Ngô Thị Phương Uyên	202417072
5	Nguyễn Thị Hải Yến	202417088

Hà Nội, 1/2026

TT	Họ và tên sinh viên	MSSV	Đóng góp
1	Trần Ngọc Mai 100%	202416976	- Thu thập và tiền xử lý tập dữ liệu - Quản lý tài liệu và tổng hợp báo cáo cuối cùng - Nghiên cứu và tổng hợp cơ sở lý thuyết của mô hình hồi quy tuyến tính - Đảm bảo nội dung cơ sở lý thuyết phù hợp với mô hình triển khai trong thực nghiệm
2	Hoàng Ngọc Thịnh 100%	202417044	- Thu thập và tiền xử lý tập dữ liệu - Chuẩn bị slide và thuyết trình mô hình thực hiện - Tổng hợp kết quả chính, biểu đồ và minh họa từ mô hình để thiết kế slide - Phân tích và diễn giải hiệu suất mô hình, chuẩn hóa hình ảnh, bảng biểu, biểu đồ trong báo cáo
3	Nguyễn Thị Thanh Trúc 100%	202417052	- Thu thập và tiền xử lý tập dữ liệu - Chuẩn bị slide và thuyết trình cơ sở lý thuyết mô hình - Tổng hợp kết quả chính, biểu đồ và minh họa từ mô hình để thiết kế slide - Đảm bảo slide thống nhất với báo cáo cuối cùng
4	Ngô Thị Phương Uyên 100%	202417072	- Thu thập và tiền xử lý tập dữ liệu - Triển khai mô hình Hồi quy tuyến tính (Linear Regression) - Ghi nhận kết quả thực nghiệm và phục vụ phân tích, viết báo cáo - Theo dõi, đảm bảo các mốc tiến độ hoàn thành đúng hạn
5	Nguyễn Thị Hải Yến 100%	202417088	- Thu thập và tiền xử lý tập dữ liệu - Xây dựng nền tảng, đề xuất các cải tiến và tinh chỉnh mô hình - Lập dàn ý và cấu trúc báo cáo tổng thể, viết báo cáo - Xử lý dữ liệu, trình bày phương pháp, mô hình, quy trình và kết quả thực nghiệm

MỤC LỤC

DANH MỤC TỪ VIẾT TẮT.....	5
DANH MỤC HÌNH ẢNH.....	7
GIỚI THIỆU	8
I. Phát biểu bài toán	9
1. Mô tả bài toán dự đoán chỉ số chất lượng không khí (AQI)	9
2. Xác định dữ liệu đầu vào và đầu ra.....	9
3. Các giả định và đơn giản hóa trong mô hình	9
II. Cơ sở lý thuyết.....	10
1. Tổng quan bài toán hồi quy	10
2. Mô hình hồi quy tuyến tính.....	10
3. Mở rộng hồi quy đa thức.....	11
4. Hàm mất mát và mục tiêu tối ưu.....	12
5. Thuật toán Gradient Descent	12
III. Dữ liệu và tiền xử lý dữ liệu	13
1. Tổng quan và vai trò của tiền xử lý dữ liệu	13
2. Mô tả tập dữ liệu	14
3. Làm sạch dữ liệu và xử lý giá trị thiếu	14
4. Chuẩn hóa và biến đổi đặc trưng	15
5. Ảnh hưởng của tiền xử lý đến quá trình hội tụ	16
IV. Phương pháp thực hiện	17
1. Cài đặt mô hình hồi quy từ đầu.....	17
2. Quy trình huấn luyện bằng Gradient Descent.....	18
3. Lựa chọn tham số và siêu tham số	19
4. Lập thí nghiệm và đánh giá.....	20
V. Kết quả và phân tích.....	23
1. Thiết lập thí nghiệm và tập đánh giá.....	23
2. Kết quả huấn luyện mô hình	23
3. Kết quả đánh giá mô hình trên tập kiểm tra.....	24

3.1	Các chỉ số đánh giá mô hình (MSE, MAE, R^2)	24
3.2	So sánh AQI thực tế và AQI dự đoán	25
4.	Ảnh hưởng của chuẩn hóa dữ liệu đến tốc độ hội tụ	26
5.	Tổng hợp kết quả thực nghiệm	27
VI.	Thảo luận	27
1.	Diễn giải hành vi của mô hình hồi quy tuyến tính	27
2.	Mối quan hệ giữa AQI thực tế và AQI dự đoán	27
3.	Phân tích hành vi hội tụ của Gradient Descent	28
4.	Ưu điểm và hạn chế của các mô hình hồi quy tuyến tính	28
4.1	Ưu điểm	28
4.2	Hạn chế	28
5.	Ý nghĩa thực tiễn của kết quả	29
VII.	Đề xuất và cải tiến	29
	KẾT LUẬN	30
	TÀI LIỆU THAM KHẢO	31

TÓM TẮT

Ô nhiễm không khí ngày càng trở thành một vấn đề nghiêm trọng, ảnh hưởng trực tiếp đến sức khỏe con người và chất lượng môi trường sống tại nhiều khu vực đô thị, đặc biệt là các thành phố lớn như Hà Nội. Bài tập lớn này trình bày quá trình xây dựng một mô hình hồi quy tuyến tính nhằm dự đoán Chỉ số chất lượng không khí (AQI) dựa trên các thông số ô nhiễm không khí. Dữ liệu được sử dụng trong nghiên cứu được thu thập từ nền tảng OpenAQ, trong đó các đặc trưng PM2.5, PM10 và NO₂ được khai thác để tính toán giá trị AQI mục tiêu theo chuẩn US EPA. Quy trình thực hiện bao gồm các bước thu thập và chuẩn bị dữ liệu, tiền xử lý, huấn luyện mô hình và đánh giá hiệu năng. Trong giai đoạn tiền xử lý, dữ liệu được chia thành tập huấn luyện và tập kiểm tra; đồng thời áp dụng kỹ thuật mở rộng đặc trưng đa thức bậc hai nhằm mô hình hóa các mối quan hệ phi tuyến, cũng như chuẩn hóa dữ liệu về trung bình bằng 0 và độ lệch chuẩn bằng 1 để cải thiện quá trình hội tụ của thuật toán Gradient Descent. Mô hình hồi quy tuyến tính được triển khai từ đầu và huấn luyện bằng thuật toán Gradient Descent trên cả dữ liệu chưa chuẩn hóa và dữ liệu đã chuẩn hóa nhằm phân tích ảnh hưởng của chuẩn hóa đến tốc độ hội tụ và giá trị hàm mất mát. Kết quả thực nghiệm cho thấy việc chuẩn hóa dữ liệu giúp mô hình hội tụ nhanh và ổn định hơn, đồng thời cải thiện đáng kể các chỉ số đánh giá trên tập kiểm tra. Mô hình đạt sai số dự đoán ở mức chấp nhận được với các chỉ số MSE, MAE, RMSE tương đối thấp và hệ số xác định R² cho thấy khả năng nắm bắt xu hướng tổng thể của AQI. Ngoài ra, các biểu đồ trực quan minh họa quá trình giảm của hàm mất mát và sự tương quan giữa AQI thực tế và AQI dự đoán cũng cho thấy mô hình hoạt động hiệu quả nhất trong khoảng AQI trung bình. Cuối cùng, mô hình được tích hợp chức năng cho phép người dùng nhập các giá trị PM2.5, PM10 và NO₂ để thực hiện dự đoán AQI, qua đó minh họa khả năng ứng dụng thực tiễn của phương pháp.

Từ khóa: Air Quality Index, PM2.5, PM10, NO₂, mô hình hồi quy tuyến tính.

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Viết đầy đủ (Tiếng Anh)	Giải thích (Tiếng Việt)
AQI	Air Quality Index	Chỉ số chất lượng không khí
PM2.5	Particulate Matter $\leq 2.5 \mu\text{m}$	Bụi mịn có đường kính ≤ 2.5 micromet
PM10	Particulate Matter $\leq 10 \mu\text{m}$	Bụi mịn có đường kính ≤ 10 micromet
NO ₂	Nitrogen Dioxide	Khí Nitơ điôxít
MSE	Mean Squared Error	Sai số bình phương trung bình
MAE	Mean Absolute Error	Sai số tuyệt đối trung bình
RMSE	Root Mean Squared Error	Căn bậc hai của sai số bình phương trung bình
R ²	Coefficient of Determination	Hệ số xác định
GD	Gradient Descent	Thuật toán hạ gradient
US EPA	United States Environmental Protection Agency	Cơ quan Bảo vệ Môi trường Hoa Kỳ
NaN	Not a Number	Giá trị không xác định trong tính toán số
Inf	Infinity	Giá trị vô cùng
ML	Machine Learning	Học máy
SISO	Single Input Single Output	Hệ thống một đầu vào – một đầu ra
API	Application Programming Interface	Giao diện lập trình ứng dụng
Train	Training set	Tập huấn luyện
Test	Test set	Tập kiểm tra

Từ viết tắt	Viết đầy đủ (Tiếng Anh)	Giải thích (Tiếng Việt)
LR	Linear Regression	Hồi quy tuyến tính
L2	L2 Regularization	Điều chuẩn L2
IQR	Interquartile Range	Khoảng tứ phân vị

DANH MỤC HÌNH ẢNH

Hình 1 Hàm tính AQI từ công thức breakpoint làm nhãn	14
Hình 2: Tính AQI nhãn cho từng biến đặc trưng.....	14
Hình 3: AQI nhãn xác định từ các đặc trưng.....	14
Hình 4: Chia tập Train-Test theo tỉ lệ 80:20	15
Hình 5: Đặc trưng Polynomial (interaction).....	16
Hình 6: Chuẩn hóa dữ liệu bằng StandardScaler.....	16
Hình 7: Kiểm tra kết quả chuẩn hóa	16
Hình 8: Cài đặt Hàm Loss và Gradient (vector hóa).....	17
Hình 9: Cài đặt Class Linear Regression.....	17
Hình 10: Khởi tạo và chuẩn bị cho huấn luyện	18
Hình 11: Lan truyền xuôi và tính hàm mất mát.....	18
Hình 12: Tính gradient và cập nhật tham số (Gradient Descent)	19
Hình 13: Theo dõi và kết thúc quá trình huấn luyện	19
Hình 14: Huấn luyện chưa scale (learning rate nhỏ).....	20
Hình 15: Huấn luyện đã scale (learning rate lớn hơn)	20
Hình 16: So sánh hội tụ trước và sau scale (loss).....	20
Hình 17: Đánh giá mô hình trên tập test.....	21
Hình 18: So sánh AQI thực tế (AQI nhãn) – dự đoán	21
Hình 19: Visualization Gradient Descent	21
Hình 20: Nhận dữ liệu đầu vào từ người dùng	21
Hình 21: Xử lý dữ liệu và dự đoán AQI	22
Hình 22: Gọi demo dự đoán	22
Hình 23: Đường cong hàm mất mát (MSE) trong quá trình huấn luyện bằng Gradient Descent.	24
Hình 24: So sánh AQI thực tế và AQI dự đoán trên tập kiểm tra.....	25
Hình 25: Ảnh hưởng của chuẩn hóa dữ liệu đến tốc độ hội tụ của Gradient Descent.	26

GIỚI THIỆU

Hồi quy tuyến tính (Linear Regression) là một trong những kỹ thuật cơ bản và được sử dụng rộng rãi nhất trong lĩnh vực học máy có giám sát. Phương pháp này mô hình hóa mối quan hệ giữa tập các đặc trưng đầu vào và một biến đầu ra liên tục bằng cách khớp một phương trình tuyến tính với dữ liệu quan sát được. Mặc dù có cấu trúc đơn giản, hồi quy tuyến tính vẫn cung cấp một mô hình nền tảng hiệu quả để phân tích hành vi của dữ liệu và đóng vai trò là cơ sở cho việc phát triển các mô hình phức tạp hơn. Trong đề tài này, chúng tôi áp dụng mô hình hồi quy tuyến tính để dự đoán chỉ số chất lượng không khí AQI dựa trên bộ dữ liệu lấy từ OpenAQ, đồng thời thực hiện các bước biến đổi đặc trưng và tối ưu hóa mô hình được xây dựng từ đầu.

Chất lượng không khí là một vấn đề quan trọng ảnh hưởng trực tiếp đến sức khỏe con người và môi trường. Việc dự đoán AQI giúp cung cấp thông tin kịp thời để cộng đồng và các nhà hoạch định chính sách có thể đưa ra các biện pháp phòng ngừa và ứng phó phù hợp. Bên cạnh đó, trong thực tế dữ liệu thường xuất hiện dưới dạng ngẫu nhiên và hỗn loạn; tuy nhiên, đằng sau những hiện tượng đó thường tồn tại các quy luật và cấu trúc tiềm ẩn. Động cơ của đề tài này xuất phát từ quan điểm *"Không có một sự kiện nào trên đời là ngẫu nhiên, những thứ đang cho là ngẫu nhiên chỉ là những sự kiện ta chưa tìm ra được mô hình để biểu diễn quy luật của chúng"*. Thông qua việc xây dựng mô hình hồi quy tuyến tính từ những nguyên lý cơ bản, bao gồm tối ưu hóa bằng thuật toán Gradient Descent và kỹ thuật xây dựng đặc trưng, đề tài hướng đến việc làm rõ quá trình học của mô hình. Cách tiếp cận thực hành này giúp nâng cao sự hiểu biết về cách mô hình phản ứng trước các phép biến đổi dữ liệu cũng như cách các tham số được học trong quá trình huấn luyện.

Bài thực hành này hướng tới các mục tiêu chính sau: **Xây dựng và triển khai mô hình Hồi quy tuyến tính:** Từ việc khởi tạo các tham số ngẫu nhiên đến quá trình học các tham số mô hình thông qua thuật toán Gradient Descent. **Hiểu rõ quy trình học tham số:** Nắm vững cách các tham số của mô hình được cập nhật để giảm thiểu hàm mất mát. **Áp dụng kỹ thuật tiền xử lý dữ liệu:** Thực hành sử dụng PolynomialFeatures để tạo các đặc trưng tương tác và StandardScaler để chuẩn hóa dữ liệu, từ đó cải thiện hiệu suất và tốc độ hội tụ của mô hình. **Đánh giá hiệu suất mô hình:** Sử dụng các chỉ số như MSE, MAE, R^2 và RMSE để đo lường độ chính xác và khả năng phù hợp của mô hình trên tập dữ liệu kiểm tra. **Minh họa tầm quan trọng của chuẩn hóa dữ liệu:** So sánh hiệu suất huấn luyện của mô hình với dữ liệu đã và chưa được chuẩn hóa. **Viết mã hiệu quả với kỹ thuật Vector hóa:** Hiểu và áp dụng cách viết code tận dụng tính toán ma trận để tối ưu hóa hiệu năng.

I. Phát biểu bài toán

1. Mô tả bài toán dự đoán chỉ số chất lượng không khí (AQI)

Bài toán được xem xét trong báo cáo này là dự đoán chỉ số chất lượng không khí (AQI) dựa trên các đại lượng môi trường quan trắc được. AQI là một đại lượng liên tục, phản ánh mức độ ô nhiễm không khí và mức độ ảnh hưởng của môi trường không khí đến sức khỏe con người. Bài toán được mô hình hóa dưới dạng bài toán hồi quy, trong đó mục tiêu là xây dựng một mô hình toán học biểu diễn mối quan hệ giữa các biến môi trường đầu vào và giá trị AQI tương ứng.

2. Xác định dữ liệu đầu vào và đầu ra

Trong bài toán dự đoán AQI, dữ liệu đầu vào bao gồm các thành phần ô nhiễm không khí được quan trắc, cụ thể là nồng độ PM_{2.5}, PM₁₀ và NO₂, đóng vai trò là các biến độc lập của mô hình. Biến đầu ra là chỉ số chất lượng không khí AQI, được xem như một biến phụ thuộc liên tục. Do đó, bài toán được biểu diễn dưới dạng ánh xạ từ tập các biến đầu vào môi trường sang một giá trị AQI tương ứng cho mỗi mẫu dữ liệu.

3. Các giả định và đơn giản hóa trong mô hình

Trong quá trình xây dựng mô hình dự đoán AQI, một số giả định và đơn giản hóa được đưa ra nhằm làm rõ bài toán và phù hợp với khuôn khổ nghiên cứu. Cụ thể, mối quan hệ giữa chỉ số AQI và các thành phần ô nhiễm không khí được giả định có thể xấp xỉ bằng một mô hình hồi quy, trong đó AQI là hàm của các biến đầu vào PM_{2.5}, PM₁₀ và NO₂.

Mô hình không xét đến sự phụ thuộc theo chuỗi thời gian giữa các mẫu dữ liệu, do đó các quan trắc được giả định là độc lập với nhau. Bên cạnh đó, các yếu tố khác có thể ảnh hưởng đến AQI trong thực tế như điều kiện khí tượng, yếu tố không gian hoặc nguồn phát thải cụ thể không được đưa vào mô hình. Những đơn giản hóa này giúp tập trung phân tích bản chất của mô hình hồi quy và quá trình tối ưu hóa, đồng thời chấp nhận rằng kết quả dự đoán chỉ mang tính xấp xỉ so với giá trị AQI thực tế.

II. Cơ sở lý thuyết

1. Tổng quan bài toán hồi quy

Hồi quy là một trong những bài toán cơ bản trong lĩnh vực mô hình hóa và dự đoán, với mục tiêu xác định mối quan hệ giữa một biến phụ thuộc và một hoặc nhiều biến độc lập thông qua một mô hình toán học [1]. Trong bối cảnh bài toán dự đoán chỉ số chất lượng không khí AQI, hồi quy được sử dụng để mô hình hóa mối quan hệ giữa AQI và các thành phần ô nhiễm không khí quan trắc được.

Cụ thể, bài toán hồi quy được biểu diễn dưới dạng xác định một hàm ánh xạ từ không gian các biến đầu vào sang giá trị đầu ra sao cho sai lệch giữa giá trị dự đoán và giá trị thực tế là nhỏ nhất theo một tiêu chuẩn nhất định. Khi biến đầu ra là đại lượng liên tục như AQI, bài toán thuộc nhóm hồi quy liên tục (regression), phù hợp để áp dụng các phương pháp tính toán số nhằm ước lượng tham số mô hình [1].

Trong báo cáo này, mô hình hồi quy đóng vai trò là công cụ trung tâm để biểu diễn mối quan hệ giữa các biến đầu vào PM2.5, PM10, NO₂ và chỉ số AQI. Việc xây dựng và phân tích mô hình hồi quy tạo cơ sở cho các bước tiếp theo như xác định hàm mất mát, tối ưu hóa tham số và đánh giá chất lượng dự đoán của mô hình.

2. Mô hình hồi quy tuyến tính

Trong bài toán dự đoán AQI, mô hình hồi quy tuyến tính được sử dụng để xấp xỉ mối quan hệ giữa chỉ số AQI và các thành phần ô nhiễm không khí đầu vào. Mô hình giả định rằng AQI có thể được biểu diễn như một tổ hợp tuyến tính của các biến đầu vào PM2.5, PM10 và NO₂ cùng với một hằng số sai lệch [2].

Cụ thể, với mỗi mẫu dữ liệu, mô hình hồi quy tuyến tính được biểu diễn dưới dạng:

$$\hat{y} = w_0 + w_1x_1 + w_2x_2 + w_3x_3$$

Trong đó:

- $\hat{y}$ là giá trị AQI dự đoán,
- x_1, x_2, x_3 lần lượt là nồng độ PM2.5, PM10 và NO₂,
- w_0, w_1, w_2, w_3 là các tham số của mô hình cần được xác định.

Để thuận tiện cho việc phân tích và tính toán, mô hình trên thường được viết dưới dạng vector – ma trận:

$$\hat{y} = \mathbf{w}^T \mathbf{x}$$

Trong đó:

- $\mathbf{x} = [1, x_1, x_2, x_3]^T$ là vector đặc trưng mở rộng,
- $\mathbf{w} = [w_0, w_1, w_2, w_3]^T$ là vector tham số tương ứng.

Dạng biểu diễn này cho phép áp dụng hiệu quả các phương pháp tính toán số và các thuật toán tối ưu hóa trong quá trình huấn luyện mô hình [2].

3. Mở rộng hồi quy đa thức

Mô hình hồi quy tuyến tính ở mục III.2 giả định mối quan hệ tuyến tính giữa các biến đầu vào và chỉ số AQI. Tuy nhiên, trong thực tế, mối quan hệ giữa các thành phần ô nhiễm không khí và AQI có thể mang tính phi tuyến [3]. Do đó, mô hình hồi quy đa thức được sử dụng như một mở rộng nhằm tăng khả năng biểu diễn của mô hình.

Trong hồi quy đa thức, các biến đầu vào được mở rộng bằng cách bổ sung các hạng phi tuyến. Ví dụ, với các biến đầu vào x_1, x_2, x_3 tương ứng với PM2.5, PM10 và NO₂, mô hình hồi quy đa thức bậc hai có thể được biểu diễn như sau:

$$\hat{y} = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_1^2 + w_5 x_2^2 + w_6 x_3^2 + w_7 x_1 x_2 + w_8 x_1 x_3 + w_9 x_2 x_3$$

Mặc dù mô hình có dạng phi tuyến theo biến đầu vào, nó vẫn **tuyến tính theo các tham số w_i** [3]. Do đó, mô hình hồi quy đa thức có thể được viết gọn dưới dạng:

$$\hat{y} = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x})$$

Trong đó:

- $\boldsymbol{\phi}(\mathbf{x})$ là vector đặc trưng sau khi mở rộng đa thức.

Cách biểu diễn này cho phép áp dụng các phương pháp huấn luyện và tối ưu tương tự như trong mô hình hồi quy tuyến tính, đồng thời cải thiện khả năng xấp xỉ các quan hệ phi tuyến giữa các biến môi trường và AQI.

4. Hàm mất mát và mục tiêu tối ưu

Để đánh giá mức độ phù hợp của mô hình hồi quy với dữ liệu, một hàm mất mát được sử dụng nhằm định lượng sai lệch giữa giá trị AQI dự đoán và giá trị AQI thực tế. Trong báo cáo này, hàm mất mát được lựa chọn là sai số bình phương trung bình (Mean Squared Error – MSE), do đặc tính khả vi và phù hợp với các bài toán hồi quy liên tục [2].

Hàm mất mát MSE được xác định như sau:

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

Trong đó:

- N là số lượng mẫu dữ liệu,
- y_i là giá trị AQI thực tế của mẫu thứ i ,
- $\hat{y}_i$ là giá trị AQI dự đoán tương ứng.

Mục tiêu của bài toán huấn luyện mô hình là tìm bộ tham số $\mathbf{w}$ sao cho giá trị của hàm mất mát đạt cực tiểu trên tập dữ liệu huấn luyện. Từ góc độ tính toán số, đây là một bài toán tối ưu hóa không ràng buộc, trong đó hàm mục tiêu chính là hàm mất mát MSE [4]. Việc giải bài toán tối ưu này tạo nền tảng cho việc áp dụng các thuật toán tối ưu lặp, được trình bày ở các mục tiếp theo.

5. Thuật toán Gradient Descent

Dựa trên hàm mất mát đã xác định ở mục III.4, bài toán huấn luyện mô hình hồi quy được giải bằng thuật toán Gradient Descent, một phương pháp tối ưu hóa lặp nhằm tìm bộ tham số làm cực tiểu hàm mất mát [4].

Gradient của hàm mất mát theo các tham số mô hình được xác định dưới dạng:

$$\nabla L(\mathbf{w}) = \frac{2}{N} X^T (X\mathbf{w} - \mathbf{y})$$

Trong đó:

- X là ma trận đặc trưng của tập dữ liệu,
- Y là vector giá trị AQI thực tế.

Quy tắc cập nhật tham số trong thuật toán Gradient Descent được viết như sau:

$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - \alpha \nabla L(\mathbf{w}^{(k)})$$

Trong đó:

- α là tốc độ học (learning rate).

Quá trình cập nhật được lặp lại cho đến khi mô hình hội tụ hoặc đạt điều kiện dừng xác định trước [4].

III. Dữ liệu và tiền xử lý dữ liệu

1. Tổng quan và vai trò của tiền xử lý dữ liệu

Trong bài toán dự đoán chỉ số chất lượng không khí (AQI), nguồn dữ liệu quan trắc môi trường thu thập từ các nền tảng công khai trên web (như OpenAQ) đóng vai trò then chốt quyết định hiệu quả của mô hình hồi quy [5]. Dữ liệu được tổng hợp từ nhiều trạm đo khác nhau, thuộc các khu vực và thời điểm không đồng nhất, nên thường tồn tại nhiều vấn đề như giá trị thiếu, giá trị không hợp lệ (NaN/Inf), nhiễu đo lường, cũng như sự chênh lệch lớn về thang đo giữa các thông số ô nhiễm (PM2.5, PM10, NO₂,...).

Đối với các thuật toán tối ưu dựa trên gradient, điển hình là Gradient Descent, những đặc điểm này của dữ liệu web có thể gây ảnh hưởng nghiêm trọng đến quá trình huấn luyện. Gradient Descent thực hiện cập nhật tham số thông qua các phép toán số học liên tục trên toàn bộ tập dữ liệu. Do đó, chỉ cần xuất hiện một giá trị không hợp lệ trong dữ liệu đầu vào, gradient của hàm mất mát có thể trở thành NaN, dẫn đến việc các tham số không còn được cập nhật đúng và khiến quá trình huấn luyện không thể hội tụ.

Vì vậy, khi sử dụng dữ liệu AQI thu thập từ web, tiền xử lý dữ liệu là bước bắt buộc, bao gồm làm sạch dữ liệu, xử lý giá trị thiếu, loại bỏ hoặc điều chỉnh các giá trị bất thường và chuẩn hóa thang đo giữa các biến. Các bước này không chỉ giúp đảm bảo tính ổn định số cho Gradient Descent mà còn nâng cao độ chính xác và khả năng tổng quát hóa của mô hình dự đoán AQI.

2. Mô tả tập dữ liệu

Tập dữ liệu được sử dụng bao gồm các bản ghi quan trắc chất lượng không khí theo ngày, thu thập trong khoảng thời gian từ 03/07/2025 đến 25/12/2025 [5]. Mỗi bản ghi tương ứng với một ngày và chứa ba đặc trưng đầu vào chính là nồng độ PM2.5, PM10 và NO₂. Biến mục tiêu là chỉ số AQI, được tính theo chuẩn US EPA và lấy giá trị lớn nhất trong các AQI thành phần tương ứng với từng chất ô nhiễm [6].

Quy trình tính chỉ số AQI thực tế theo US EPA [6]

```
def calc_aqi(Cp, breakpoints):  
    for C_lo, C_hi, I_lo, I_hi in breakpoints:  
        if C_lo <= Cp <= C_hi:  
            return (I_hi - I_lo)/(C_hi - C_lo) * (Cp - C_lo) + I_lo  
    return np.nan
```

Hình 1 Hàm tính AQI từ công thức breakpoint làm nhãn

```
df['AQI_PM25'] = df['PM2.5'].apply(lambda x: calc_aqi(x, bp_pm25))  
df['AQI_PM10'] = df['PM10'].apply(lambda x: calc_aqi(x, bp_pm10))  
df['AQI_NO2'] = df['NO2'].apply(lambda x: calc_aqi(x, bp_no2))
```

Hình 2: Tính AQI nhãn cho từng biến đặc trưng

```
df['AQI'] = df[['AQI_PM25', 'AQI_PM10', 'AQI_NO2']].max(axis=1)
```

Hình 3: AQI nhãn xác định từ các đặc trưng

Về mặt cấu trúc, đây là một bài toán hồi quy với số chiều đầu vào thấp (ba đặc trưng gốc). Tuy nhiên, các biến này có sự khác biệt đáng kể về đơn vị đo và mức độ biến thiên, khiến bài toán trở nên nhạy cảm với việc lựa chọn và triển khai thuật toán tối ưu nếu không có tiền xử lý phù hợp.

3. Làm sạch dữ liệu và xử lý giá trị thiếu

3.1 Kiểm tra tính đầy đủ của dữ liệu

Bước đầu tiên trong tiền xử lý là kiểm tra tính đầy đủ của dữ liệu trong toàn bộ khoảng thời gian nghiên cứu. Việc kiểm tra tập trung vào hai trường hợp: (i) các ngày bị thiếu một hoặc nhiều giá trị PM2.5, PM10 hoặc NO₂, và (ii) các ngày bị thiếu hoàn toàn dữ liệu quan trắc.

Bước này đặc biệt quan trọng bởi Gradient Descent không thể xử lý trực tiếp các giá trị thiếu. Chỉ một điểm dữ liệu chứa NaN cũng đủ để làm cho gradient của hàm mất mát trở thành NaN, dẫn đến việc cập nhật tham số không còn ý nghĩa và quá trình huấn luyện bị gián đoạn.

3.2 Chiến lược xử lý giá trị thiếu

Tùy theo mức độ thiếu hụt của dữ liệu, hai chiến lược xử lý được áp dụng. Trong trường hợp số lượng ngày bị thiếu là rất ít so với tổng số mẫu, các bản ghi này được loại bỏ nhằm đảm bảo tính nhất quán của tập dữ liệu. Ngược lại, nếu dữ liệu bị thiếu với tần suất lớn hơn, các giá trị thiếu được thay thế bằng giá trị trung bình của biến tương ứng để duy trì kích thước tập dữ liệu và hạn chế làm sai lệch phân phối tổng thể.

Các chiến lược đơn giản này được lựa chọn nhằm đảm bảo quy trình tiền xử lý minh bạch, dễ diễn giải và phù hợp với mục tiêu minh họa thuật toán Gradient Descent trong khuôn khổ môn học.

4. Chuẩn hóa và biến đổi đặc trưng

Sau khi làm sạch, bộ dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo tỷ lệ 80% train và 20% test. Việc chia dữ liệu được thực hiện trước các bước biến đổi nhằm tránh hiện tượng rò rỉ dữ liệu từ tập kiểm tra vào quá trình huấn luyện.

```
X_train, X_test, y_train, y_test = train_test_split(  
    X, y, test_size=0.2, random_state=42  
)
```

Hình 4: Chia tập Train-Test theo tỉ lệ 80:20

Để nắm bắt các mối quan hệ phi tuyến tiềm ẩn giữa các biến môi trường, tập đặc trưng được mở rộng bằng phương pháp hồi quy đa thức thông qua Polynomial Features với $\text{degree} = 2$, $\text{interaction_only} = \text{True}$ và $\text{include_bias} = \text{False}$ [7]. Cấu hình này chỉ tạo ra các hạng tương tác theo cặp giữa các biến PM2.5, PM10 và NO₂, đồng thời loại bỏ các hạng bình phương và hệ số lệch hằng, giúp kiểm soát độ phức tạp của mô hình và giảm nguy cơ quá khớp. Kết quả là số lượng đặc trưng tăng từ 3 lên 6.


```
poly = PolynomialFeatures(
    degree=2,
    include_bias=False,
    interaction_only=True
)

X_train_poly = poly.fit_transform(X_train)
X_test_poly = poly.transform(X_test)
```

Hình 5: Đặc trưng Polynomial (interaction)

Sau khi mở rộng, các đặc trưng được chuẩn hóa bằng phương pháp standard, đưa mỗi đặc trưng về phân phối có trung bình bằng 0 và độ lệch chuẩn bằng 1 [7]. Quá trình chuẩn hóa được fit trên tập huấn luyện và sau đó áp dụng cho tập kiểm tra nhằm đảm bảo đánh giá công bằng và tránh rò rỉ dữ liệu.

```
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train_poly)
X_test_scaled = scaler.transform(X_test_poly)
```

Hình 6: Chuẩn hóa dữ liệu bằng StandardScaler

```
print(X_train_scaled.shape)
print(np.mean(X_train_scaled, 0))
print(np.std(X_train_scaled, 0))
```

Hình 7: Kiểm tra kết quả chuẩn hóa

5. Ảnh hưởng của tiền xử lý đến quá trình hội tụ

Chuẩn hóa dữ liệu có ảnh hưởng trực tiếp đến tốc độ và tính ổn định của Gradient Descent. Khi dữ liệu không được chuẩn hóa, các đặc trưng có thang đo lớn sẽ chi phối gradient, làm cho các đường đồng mức của hàm mất mát bị kéo dài và méo mó. Điều này khiến Gradient Descent di chuyển theo quỹ đạo zig-zag và cần nhiều vòng lặp hơn để hội tụ.

Ngược lại, khi dữ liệu được chuẩn hóa, các đặc trưng đóng góp cân bằng hơn vào gradient, giúp hàm mất mát có dạng gần tròn hơn trong không gian tham số. Nhờ đó, Gradient Descent hội tụ nhanh hơn, ổn định hơn và giảm nguy cơ mắc kẹt ở các nghiệm tối ưu kém.

IV. Phương pháp thực hiện

1. Cài đặt mô hình hồi quy từ đầu

Mô hình hồi quy tuyến tính được cài đặt thủ công từ đầu bằng Python, trong đó toàn bộ quá trình huấn luyện được triển khai trực tiếp thông qua thuật toán Gradient Descent, bao gồm việc xác định hàm mất mát, tính gradient và cập nhật tham số. Trọng số và hệ số chặn của mô hình được khởi tạo ngẫu nhiên và được cập nhật lặp lại trong quá trình huấn luyện cho đến khi hội tụ.

Bên cạnh mô hình tự cài đặt, LinearRegression của thư viện scikit-learn vẫn được sử dụng như một mô hình tham chiếu, nhằm so sánh kết quả dự đoán và đánh giá hiệu quả của phương pháp huấn luyện Gradient Descent do nhóm tự triển khai [7]. Việc sử dụng sklearn.LinearRegression không nhằm thay thế quá trình huấn luyện thủ công, mà đóng vai trò đối chứng để kiểm chứng tính đúng đắn và độ tin cậy của mô hình tự xây dựng.

```
def linear_loss_vectorized(X, y, w, b):  
    n = len(y)  
    # Dự đoán  
    y_hat = np.dot(X, w) + b  
    # Sai số  
    errors = y - y_hat  
    # Loss (MSE)  
    loss = np.mean(errors ** 2)  
    # Gradient  
    dw = -2 * np.dot(X.T, errors) / n  
    db = -2 * np.mean(errors)  
    return loss, dw, db
```

Hình 8: Cài đặt Hàm Loss và Gradient (vector hóa)

```
class LinearRegression:  
    def __init__(self):  
        self.w = None  
        self.b = None
```

Hình 9: Cài đặt Class Linear Regression

2. Quy trình huấn luyện bằng Gradient Descent

Quy trình huấn luyện bao gồm các bước:

- Tính giá trị dự đoán của mô hình
- Xác định hàm mất mát Mean Squared Error (MSE)
- Tính gradient của hàm mất mát theo từng tham số
- Cập nhật tham số theo hướng ngược với gradient

Quy trình này được lặp lại trong nhiều vòng (epochs) cho đến khi mô hình hội tụ.

Trước khi tiến hành Gradient Descent, mô hình xác định số mẫu, số đặc trưng, chuẩn hóa nhãn và khởi tạo các tham số ban đầu. Trọng số được khởi tạo với giá trị nhỏ ngẫu nhiên nhằm tránh hiện tượng bão hòa. Đồng thời, lịch sử hàm mất mát được lưu lại để phục vụ việc đánh giá quá trình học.

```
n_samples, n_features = X.shape
y = np.asarray(y).reshape(-1, 1)

self.w = np.random.normal(0, 0.01, (n_features, 1))
self.b = np.mean(y)

loss_hist = []
```

Hình 10: Khởi tạo và chuẩn bị cho huấn luyện

Ở mỗi vòng lặp, mô hình thực hiện lan truyền xuôi để dự đoán đầu ra và tính sai số dựa trên hàm mất mát MSE, qua đó đánh giá mức độ sai lệch giữa AQI dự đoán và AQI thực tế.

```
y_hat = np.dot(X, self.w) + self.b
errors = y_hat - y

loss = np.mean(errors ** 2)
loss_hist.append(loss)
```

Hình 11: Lan truyền xuôi và tính hàm mất mát

Gradient của hàm mất mát theo trọng số và bias được tính toán và sử dụng để cập nhật tham số theo thuật toán Gradient Descent với learning rate giảm dần. Việc áp dụng learning rate decay giúp quá trình hội tụ diễn ra ổn định hơn và hạn chế dao động quanh nghiệm tối ưu.

```
dw = np.dot(X.T, errors) / n_samples
db = np.mean(errors)

lr = learning_rate / (1 + 0.001 * it)

self.w -= lr * dw
self.b -= lr * db
```

Hình 12: Tính gradient và cập nhật tham số (Gradient Descent)

Trong suốt quá trình huấn luyện, giá trị loss được theo dõi và in ra định kỳ nhằm kiểm tra xu hướng hội tụ của mô hình. Dữ liệu loss_hist được sử dụng để trực quan hóa quá trình học.

```
if it % 200 == 0:
    print(f"Iteration {it}, Loss: {loss:.4f}")

return loss_hist
```

Hình 13: Theo dõi và kết thúc quá trình huấn luyện

3. Lựa chọn tham số và siêu tham số

Các siêu tham số chính của mô hình bao gồm learning rate và số vòng lặp huấn luyện. Các giá trị này được lựa chọn thông qua thử nghiệm nhằm đảm bảo mô hình hội tụ ổn định mà không bị dao động hoặc phân kỳ.

Sau khi chuẩn hóa dữ liệu, mô hình được huấn luyện trong hai kịch bản: (i) huấn luyện không chuẩn hóa dữ liệu, với learning rate nhỏ; (ii) huấn luyện có chuẩn hóa dữ liệu, cho phép sử dụng learning rate lớn hơn.

Sự so sánh này giúp làm rõ vai trò của chuẩn hóa dữ liệu đối với hiệu quả huấn luyện của Gradient Descent.

```

model_raw = LinearRegression()
loss_raw = model_raw.train(
    X_train,
    y_train,
    learning_rate=1e-6,
    num_iters=2000
)

```

Hình 14: Huấn luyện chưa scale (learning rate nhỏ)

```

model_scaled = LinearRegression()
loss_scaled = model_scaled.train(
    X_train_scaled,
    y_train,
    learning_rate=0.01,
    num_iters=2000
)

```

Hình 15: Huấn luyện đã scale (learning rate lớn hơn)

4. Lập thí nghiệm và đánh giá

Mô hình được đánh giá trên tập kiểm tra thông qua các chỉ số sai số hồi quy. Kết quả huấn luyện với dữ liệu đã tiền xử lý được so sánh với trường hợp không chuẩn hóa nhằm làm rõ ảnh hưởng của tiền xử lý đến khả năng hội tụ và hiệu quả dự đoán của Gradient Descent. Phần này tập trung vào việc so sánh, đánh giá và trực quan hóa kết quả.

```

plt.plot(loss_raw, label='Without scaling')
plt.plot(loss_scaled, label='With scaling')
plt.legend()
plt.show()

```

Hình 16: So sánh hội tụ trước và sau scale (loss)

```
mse, mae, r2, y_pred = model_scaled.evaluate(X_test_scaled, y_test)

print(f"MSE : {mse:.4f}")
print(f"MAE : {mae:.4f}")
print(f"R2 : {r2:.4f}")
print(f"RMSE: {np.sqrt(mse):.4f}")
```

Hình 17: Đánh giá mô hình trên tập test

```
plt.scatter(index, y_test, alpha=0.6, label='AQI thực tế')
plt.scatter(index, y_pred, alpha=0.6, label='AQI dự đoán', marker='x')
```

Hình 18: So sánh AQI thực tế (AQI nhãn) – dự đoán

```
ax1.plot(loss_scaled)
ax1.set_title("Hàm mất mát trong quá trình Gradient Descent")
```

Hình 19: Visualization Gradient Descent

Hệ thống cho phép người dùng nhập thủ công nồng độ PM2.5, PM10 và NO₂. Dữ liệu đầu vào được kiểm tra tính hợp lệ (không âm) và được chuẩn hóa về đúng dạng shape (1, 3).

```
def get_user_input_aqi():
    features = ['PM2.5', 'PM10', 'NO2']
    values = []

    for f in features:
        while True:
            try:
                v = float(input(f"Nhập {f}: "))
                if v < 0:
                    raise ValueError
                values.append(v)
                break
            except ValueError:
                print("Giá trị không hợp lệ, nhập lại.")

    return np.array(values).reshape(1, 3)
```

Hình 20: Nhận dữ liệu đầu vào từ người dùng

Dữ liệu sau đó được đưa qua cùng pipeline tiền xử lý như dữ liệu huấn luyện nhằm đảm bảo tính nhất quán giữa giai đoạn train và inference. Mô hình đã huấn luyện được kích hoạt để dự đoán và xuất ra giá trị AQI tương ứng.

```
def predict_aqi_from_input(model, poly, scaler):  
    X_new = get_user_input_aqi()  
  
    # Polynomial  
    X_new_poly = poly.transform(X_new)  
  
    # Scale  
    X_new_scaled = scaler.transform(X_new_poly)  
  
    # Predict AQI  
    y_pred = model.predict(X_new_scaled)  
  
    print(f"\nAQI dự đoán: {y_pred[0][0]:.2f}")
```

Hình 21: Xử lý dữ liệu và dự đoán AQI

```
predict_aqi_from_input(model_scaled, poly, scaler)
```

Hình 22: Gọi demo dự đoán

V. Kết quả và phân tích

1. Thiết lập thí nghiệm và tập đánh giá

Trong nghiên cứu này, tập dữ liệu ban đầu được chia thành hai phần: tập huấn luyện (training set) và tập kiểm tra (test set) theo tỷ lệ 80% – 20%. Việc chia dữ liệu được thực hiện ngẫu nhiên nhưng có cố định tham số `random_state` nhằm đảm bảo khả năng tái lập kết quả trong các lần chạy khác nhau.

Tập huấn luyện được sử dụng để học các tham số của mô hình hồi quy tuyến tính, bao gồm vector trọng số và hệ số chệch, thông qua thuật toán Gradient Descent. Trong khi đó, tập kiểm tra được giữ hoàn toàn độc lập và chỉ được sử dụng cho mục đích đánh giá, nhằm phản ánh khả năng tổng quát hóa của mô hình trên dữ liệu chưa từng xuất hiện trong quá trình huấn luyện.

Đối với mỗi mẫu dữ liệu, các đặc trưng đầu vào bao gồm nồng độ PM2.5, PM10 và NO₂. Trước khi đưa vào mô hình, các đặc trưng này được mở rộng bằng Polynomial Features bậc hai (interaction terms) và chuẩn hóa bằng StandardScaler, với các tham số chuẩn hóa được học chỉ trên tập huấn luyện và sau đó áp dụng cho tập kiểm tra. Quy trình này đảm bảo tính nhất quán giữa dữ liệu huấn luyện và dữ liệu đánh giá, đồng thời tránh hiện tượng rò rỉ thông tin (data leakage).


Hiệu quả của mô hình được đánh giá trên tập kiểm tra thông qua các chỉ số phổ biến trong bài toán hồi quy, bao gồm Mean Squared Error (MSE), Mean Absolute Error (MAE), Root Mean Squared Error (RMSE) và hệ số xác định R^2 [1]. Ngoài ra, các kết quả dự đoán còn được trực quan hóa bằng đồ thị để hỗ trợ phân tích định tính về mức độ phù hợp giữa AQI thực tế và AQI dự đoán.

2. Kết quả huấn luyện mô hình

Quá trình huấn luyện mô hình hồi quy tuyến tính được thực hiện bằng thuật toán Gradient Descent, trong đó hàm mất mát sử dụng là Mean Squared Error (MSE). Để đánh giá hành vi học của mô hình, giá trị hàm mất mát được ghi nhận theo từng vòng lặp huấn luyện và biểu diễn dưới dạng đồ thị. Hình 6.1 minh họa sự thay đổi của hàm mất mát MSE theo số vòng lặp trong quá trình huấn luyện mô hình bằng Gradient Descent trên dữ liệu đã được chuẩn hóa.

Quan sát cho thấy giá trị hàm mất mát giảm rất nhanh trong những vòng lặp đầu tiên, sau đó giảm chậm dần và tiến tới ổn định khi số vòng lặp tăng lên. Hiện tượng này phản ánh việc mô hình nhanh chóng điều chỉnh các tham số từ trạng thái khởi tạo ban đầu về vùng lân cận nghiệm tối ưu, trước khi hội tụ hoàn toàn.

Đường cong hàm mất mát không xuất hiện hiện tượng dao động mạnh hoặc tăng trở lại, cho thấy việc lựa chọn learning rate là phù hợp và quá trình cập nhật tham số diễn ra ổn định. Kết quả này khẳng định rằng thuật toán Gradient Descent đã hội tụ và mô hình được huấn luyện thành công.



Hình 23: Đường cong hàm mất mát (MSE) trong quá trình huấn luyện bằng Gradient Descent.

3. Kết quả đánh giá mô hình trên tập kiểm tra

3.1 Các chỉ số đánh giá mô hình (MSE, MAE, R^2)

Sau khi huấn luyện, mô hình được đánh giá trên tập kiểm tra thông qua các chỉ số MSE, MAE và R^2 . Các chỉ số này phản ánh mức độ sai lệch trung bình giữa AQI dự đoán và AQI thực tế, cũng như khả năng giải thích phương sai của mô hình [1].


Kết quả cho thấy mô hình đạt sai số dự đoán ở mức chấp nhận được, với MAE tương đối thấp so với thang giá trị của AQI. Đồng thời, hệ số R^2 cho thấy mô hình có khả năng nắm bắt được xu hướng tổng thể của dữ liệu AQI, dù chưa thể mô tả hoàn hảo mọi biến động.

3.2 So sánh AQI thực tế và AQI dự đoán

Để đánh giá trực quan chất lượng dự đoán của mô hình, hình 6.2 biểu diễn mối quan hệ giữa **AQI thực tế** và **AQI dự đoán** trên tập kiểm tra dưới dạng đồ thị phân tán. Trong đó đường đứt nét $y = x$ biểu thị trường hợp dự đoán lý tưởng, mỗi điểm dữ liệu biểu diễn một mẫu kiểm tra, với trục hoành là AQI thực tế và trục tung là AQI dự đoán.

Quan sát đồ thị cho thấy phần lớn các điểm dữ liệu tập trung xung quanh đường lý tưởng $y = x$, đặc biệt trong khoảng AQI trung bình, cho thấy mô hình dự đoán AQI khá sát với giá trị thực tế trong nhiều trường hợp. Điều này phản ánh khả năng mô hình hóa tốt xu hướng chung của mô hình hồi quy tuyến tính sau khi được mở rộng đặc trưng và chuẩn hóa.

Tuy nhiên, tại các giá trị AQI cao, sai lệch giữa AQI dự đoán và AQI thực tế có xu hướng tăng lên. Điều này cho thấy mô hình gặp khó khăn trong việc mô tả chính xác các trường hợp AQI cực trị, vốn chịu ảnh hưởng của các ngưỡng và đặc tính phi tuyến trong công thức tính AQI.




Hình 24: So sánh AQI thực tế và AQI dự đoán trên tập kiểm tra

4. Ảnh hưởng của chuẩn hóa dữ liệu đến tốc độ hội tụ

Để đánh giá vai trò của bước chuẩn hóa dữ liệu, mô hình được huấn luyện trong hai trường hợp: có chuẩn hóa dữ liệu và không chuẩn hóa dữ liệu. Kết quả được so sánh thông qua đồ thị hàm mất mát theo số vòng lặp.

Quan sát kết quả thu được từ hình 6.3, trong trường hợp không chuẩn hóa, do các đặc trưng đầu vào có thang đo khác nhau, Gradient Descent cần sử dụng learning rate rất nhỏ để tránh hiện tượng phân kỳ, dẫn đến tốc độ hội tụ chậm. Ngược lại, khi dữ liệu được chuẩn hóa, các đặc trưng được đưa về cùng thang đo, giúp gradient giữa các chiều trở nên cân bằng hơn.

Kết quả thực nghiệm cho thấy chuẩn hóa dữ liệu giúp giảm đáng kể số vòng lặp cần thiết để hội tụ, đồng thời làm cho quá trình huấn luyện ổn định hơn. Điều này khẳng định vai trò quan trọng của tiền xử lý dữ liệu trong các mô hình tối ưu hóa dựa trên gradient.



Hình 25: Ảnh hưởng của chuẩn hóa dữ liệu đến tốc độ hội tụ của Gradient Descent.

5. Tổng hợp kết quả thực nghiệm

Từ các thí nghiệm đã thực hiện, có thể rút ra một số nhận xét chính như sau. Mô hình hồi quy tuyến tính sau khi được mở rộng đặc trưng và chuẩn hóa dữ liệu đã hội tụ ổn định trong quá trình huấn luyện. Trên tập kiểm tra, mô hình đạt sai số dự đoán ở mức chấp nhận được và có khả năng nắm bắt xu hướng tổng thể của chỉ số AQI.

Bên cạnh đó, các kết quả trực quan cho thấy mô hình hoạt động tốt nhất trong khoảng AQI trung bình, trong khi sai lệch tăng lên tại các giá trị AQI cao. Việc chuẩn hóa dữ liệu đóng vai trò then chốt trong việc cải thiện tốc độ hội tụ và hiệu quả huấn luyện của thuật toán Gradient Descent.

VI. Thảo luận

1. Diễn giải hành vi của mô hình hồi quy tuyến tính

Các kết quả thực nghiệm cho thấy mô hình hồi quy tuyến tính sau khi được mở rộng đặc trưng và chuẩn hóa dữ liệu có khả năng dự đoán AQI ở mức chấp nhận được, đặc biệt trong khoảng AQI trung bình. Điều này cho thấy mối quan hệ tuyến tính (kết hợp với các đặc trưng tương tác) giữa các thông số ô nhiễm và AQI có thể mô tả tương đối tốt xu hướng chung của dữ liệu.

Tuy nhiên, mô hình vẫn tồn tại sai lệch đáng kể tại các giá trị AQI cao. Hiện tượng này phản ánh hạn chế cố hữu của mô hình hồi quy tuyến tính khi phải mô tả các mối quan hệ phức tạp hơn trong dữ liệu môi trường, đặc biệt là các trường hợp cực trị, nơi ảnh hưởng của từng chất ô nhiễm không còn tuyến tính đơn giản.

2. Mối quan hệ giữa AQI thực tế và AQI dự đoán

Trong nghiên cứu này, AQI thực tế được sử dụng làm nhãn huấn luyện và được tính trực tiếp từ công thức breakpoint tiêu chuẩn dựa trên các nồng độ PM_{2.5}, PM₁₀ và NO₂ [6]. Công thức này mang tính phi tuyến và có ngưỡng, đồng thời AQI tổng được xác định bằng cách lấy giá trị lớn nhất trong các AQI thành phần.

Ngược lại, AQI dự đoán là kết quả của mô hình hồi quy tuyến tính, trong đó mối quan hệ giữa các thông số ô nhiễm và AQI được xấp xỉ bằng một hàm tuyến tính theo tham

số. Do đó, mô hình không thể biểu diễn chính xác các điểm gãy và ngưỡng đặc trưng của công thức AQI, dẫn đến 4ai lệch tăng lên tại các vùng AQI cao.

Kết quả này cho thấy mô hình hồi quy tuyến tính phù hợp để xấp xỉ xu hướng tổng thể của AQI, nhưng không nhằm thay thế hoàn toàn công thức AQI chuẩn trong các trường hợp yêu cầu độ chính xác cao tại các vùng cực trị.

3. Phân tích hành vi hội tụ của Gradient Descent

Đồ thị hàm mất mát theo số vòng lặp cho thấy thuật toán Gradient Descent hội tụ ổn định khi dữ liệu được chuẩn hóa. Trong giai đoạn đầu, hàm mất mát giảm nhanh do các tham số được điều chỉnh mạnh từ trạng thái khởi tạo ngẫu nhiên. Khi tiến gần nghiệm tối ưu, gradient giảm dần và tốc độ giảm của hàm mất mát chậm lại, phản ánh hành vi hội tụ điển hình của Gradient Descent.

Việc chuẩn hóa dữ liệu đóng vai trò then chốt trong quá trình này. Khi các đặc trưng đầu vào có cùng thang đo, gradient theo các chiều trở nên cân bằng hơn, cho phép sử dụng learning rate lớn hơn mà không gây mất ổn định. Ngược lại, khi không chuẩn hóa, Gradient Descent phải sử dụng learning rate rất nhỏ để tránh phân kỳ, dẫn đến tốc độ hội tụ chậm và kém hiệu quả.

4. Ưu điểm và hạn chế của các mô hình hồi quy tuyến tính

4.1 Ưu điểm

Mô hình hồi quy tuyến tính có cấu trúc đơn giản, dễ cài đặt và dễ diễn giải. Các tham số của mô hình cho phép đánh giá định tính ảnh hưởng của từng thông số ô nhiễm đến chỉ số AQI. Ngoài ra, mô hình có tốc độ huấn luyện nhanh và phù hợp làm nền tảng cho việc nghiên cứu các phương pháp học máy phức tạp hơn.

4.2 Hạn chế

Do bản chất tuyến tính, mô hình không thể mô tả chính xác các mối quan hệ phi tuyến mạnh và các ngưỡng trong công thức tính AQI. Điều này dẫn đến sai lệch tại các giá trị AQI cao hoặc trong các trường hợp ô nhiễm bất thường. Bên cạnh đó, mô hình phụ thuộc đáng kể vào chất lượng dữ liệu đầu vào và không xử lý trực tiếp được các yếu tố môi trường khác như điều kiện khí tượng.

5. Ý nghĩa thực tiễn của kết quả

Mặc dù tồn tại một số hạn chế, kết quả nghiên cứu cho thấy mô hình hồi quy tuyến tính vẫn có ý nghĩa thực tiễn trong việc xấp xỉ nhanh chỉ số AQI từ các thông số ô nhiễm cơ bản. Mô hình có thể được sử dụng như một công cụ hỗ trợ phân tích, hoặc làm bước trung gian trong các hệ thống dự báo AQI phức tạp hơn.

Quan trọng hơn, nghiên cứu này giúp làm rõ vai trò của tiền xử lý dữ liệu, đặc biệt là chuẩn hóa, trong các thuật toán tối ưu hóa dựa trên gradient. Những kết quả đạt được tạo tiền đề cho việc mở rộng sang các mô hình phi tuyến hoặc các phương pháp học máy nâng cao trong các nghiên cứu tiếp theo.

VII. Đề xuất và cải tiến

Để nâng cao hiệu năng và độ ổn định của mô hình Hồi quy tuyến tính hiện tại, một số hướng cải tiến có thể được xem xét trong các nghiên cứu tiếp theo:

1. **Xây dựng đặc trưng (Feature Engineering):** Bổ sung các đặc trưng tương tác hoặc đặc trưng đa thức có thể giúp mô hình nắm bắt các mối quan hệ phi tuyến mà hồi quy tuyến tính thuần túy không thể mô hình hóa hiệu quả.
2. **Phát hiện và xử lý ngoại lai:** Mô hình cho thấy độ nhạy cao với các giá trị ngoại lai, đặc biệt trong việc dự đoán các giá trị lớn. Việc áp dụng các phương pháp phát hiện ngoại lai (ví dụ: lọc theo z-score hoặc phương pháp IQR) có thể làm giảm phương sai dự đoán và cải thiện độ chính xác tổng thể.
3. **Tinh chỉnh siêu tham số (Hyperparameter Tuning):** Thử nghiệm với các giá trị khác nhau của tốc độ học, hệ số điều chuẩn và số vòng lặp huấn luyện có thể giúp mô hình hội tụ tốt hơn và cải thiện khả năng tổng quát hóa.
4. **So sánh mô hình:** Việc triển khai và so sánh với các mô hình nâng cao hơn như Ridge Regression, Lasso Regression, Cây quyết định (Decision Trees) hoặc các phương pháp tổ hợp như Random Forest và Gradient Boosting có thể mang lại khả năng dự đoán và tính linh hoạt cao hơn.
5. **Xác thực chéo (Cross-Validation):** Áp dụng phương pháp xác thực chéo k-fold giúp đảm bảo hiệu năng của mô hình ổn định và không phụ thuộc quá nhiều vào một cách chia tập huấn luyện–kiểm tra cụ thể.

6. **Chuẩn hóa dữ liệu:** Việc chuẩn hóa hoặc chuẩn hóa tỉ lệ các đặc trưng có thể cải thiện hành vi hội tụ của thuật toán và giúp mô hình gán trọng số cho các đặc trưng một cách hợp lý hơn.

Thông qua việc mở rộng theo các hướng trên, hiệu năng dự đoán của mô hình có thể được cải thiện đáng kể, từ đó nâng cao tính tin cậy khi áp dụng trong các bài toán thực tiễn.

KẾT LUẬN

Trong đề tài này, mô hình Hồi quy tuyến tính đã được triển khai thành công để dự đoán chỉ số chất lượng không khí. Mô hình được huấn luyện bằng thuật toán Gradient Descent kết hợp với điều chuẩn L2 nhằm cực tiểu hóa hàm mất mát Sai số bình phương trung bình (Mean Squared Error – MSE). Trong suốt quá trình huấn luyện, hàm mất mát thể hiện xu hướng hội tụ rõ ràng, cho thấy mô hình đã học được các mẫu và mối quan hệ có ý nghĩa từ các đặc trưng đầu vào.

Các chỉ số đánh giá như MSE, MAE và hệ số xác định R^2 cho thấy mô hình có khả năng nắm bắt xu hướng tổng quát của dữ liệu, tuy nhiên vẫn gặp khó khăn trong việc dự đoán chính xác các giá trị ngoại lai có mức cao. Việc trực quan hóa dữ liệu thông qua so sánh giữa giá trị thực tế và giá trị dự đoán cũng cho thấy mô hình có xu hướng dự đoán thấp hơn thực tế trong một số trường hợp, đồng thời thể hiện hạn chế trong việc mô hình hóa các mối quan hệ phi tuyến.

Nhìn chung, mặc dù phương pháp hồi quy tuyến tính đã được áp dụng hiệu quả và mang lại kết quả ở mức chấp nhận được, mô hình vẫn còn dư địa để cải thiện. Việc nâng cao mô hình thông qua xây dựng đặc trưng, xử lý ngoại lai hoặc áp dụng các mô hình phức tạp hơn như hồi quy đa thức hoặc các phương pháp tổ hợp (ensemble) có thể giúp cải thiện độ chính xác dự đoán, đặc biệt đối với các giá trị cực trị.

TÀI LIỆU THAM KHẢO

- [1] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: With Applications in R*, New York, NY, USA: Springer, 2013.
- [2] D. C. Montgomery, E. A. Peck, and G. G. Vining, *Introduction to Linear Regression Analysis*, 5th ed., Hoboken, NJ, USA: Wiley, 2012.
- [3] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York, NY, USA: Springer, 2009.
- [4] S. Boyd and L. Vandenberghe, *Convex Optimization*, Cambridge, U.K.: Cambridge University Press, 2004.
- [5] OpenAQ, “Open Air Quality Data Platform,” [Online]. Available: <https://openaq.org/>, Accessed: Jan. 1, 2026.
- [6] U.S. Environmental Protection Agency, “Technical Assistance Document for the Reporting of Daily Air Quality – the Air Quality Index (AQI),” Washington, DC, USA, 2018. [Online]. Available: <https://www.epa.gov/air-quality-index>, Accessed: Jan. 1, 2026.
- [7] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: <https://scikit-learn.org/>